

Lecture Series 2 – Probabilistic & Information: Theoretic Foundations

목차

Chapter 3. 베이지 의사결정과 판별 (Bayesian Decision and Discrimination)

강의 개요 (Chapter Overview)

A. 베이지 위험과 비용민감 학습 (Bayes Risk and Cost-Sensitive Learning)

A.1. 사례: 의료 진단의 비대칭적 비용 (Case: Asymmetric Costs in Medical Diagnosis)

A.2. 이론: 결정 규칙, 임계값 최적화, 정규화 사전의 역할 (Theory: Decision Rule, Threshold Optimization, Role of Regularization Prior)

A.3. 예제(퀴즈): 최적 임계값 선택 (Example(Quiz): Select the Optimal Threshold)

B. 일반화 선형모형(GLM)과 링크함수 (Generalized Linear Models (GLM) and Link Functions)

B.1. 사례: 다양한 데이터 유형에 대한 회귀 분석 (Case: Regression for Various Data Types)

B.2. 이론: 지수족, 캐노니컬 링크, MLE (Theory: Exponential Family, Canonical Link, MLE)

B.3. 예제(퀴즈): 지수족 로그우도 형태 식별 (Example(Quiz): Identify Exponential Family Form)

C. 보정(calibration)과 예측확률의 품질 (Calibration and Quality of Predicted Probabilities)

C.1. 사례: 날씨 예측의 신뢰도 (Case: Reliability of Weather Forecasts)

C.2. 이론: 브라이어 점수 / ECE 개념 (Theory: Brier Score / ECE Concept)

C.3. 예제(퀴즈): 주어진 버킷의 Brier 계산 (Example(Quiz): Calculate Brier Score for a Given Bucket)

챕터 요약 및 다음 단계 (Chapter Summary & Next Steps)

Chapter 3. 베이지 의사결정과 판별 (Bayesian Decision and Discrimination)

강의 개요 (Chapter Overview)

이전 챕터에서 우리는 확률 모델을 통해 데이터의 불확실성을 표현하는 방법을 배웠습니다. 이번 챕터에서는 한 걸음 더 나아가, 그 확률적 예측을 바탕으로 '최적의 의사결정'을 내리는 방법을 탐구합니다. 현실 세계의 문제는 단순히 예측 정확도만으로 평가되지 않습니다. 잘못된 결정이 초래하는 '비용'이나 '위험'을 고려해야 하며, 모델이 제시하는 '확률'의 신뢰도를 평가하는 것 또한 중요합니다.

본 챕터에서는 다음 세 가지 핵심 주제를 통해 확률 모델을 실제 의사결정에 적용하는 과정을 학습합니다.

- 베이지 위험과 비용민감 학습:** 모든 오류가 동일한 비용을 갖지 않는 현실적인 문제(예: 의료 진단)에서, 총 기대 비용(위험)을 최소화하는 최적의 결정 경계를 찾는 방법을 배웁니다.
- 일반화 선형 모형(GLM):** 반응 변수가 정규분포를 따르지 않는 다양한 데이터(예: 사건 발생 횟수, 성공/실패)를 모델링하기 위한 통합된 프레임워크를 학습합니다.
- 보정(Calibration):** 모델이 예측한 확률이 실제 발생 빈도와 얼마나 일치하는지, 즉 예측 확률의 '품질'을 정량적으로 평가하고 보정하는 방법을 다룹니다.

A. 베이지 위험과 비용민감 학습 (Bayes Risk and Cost-Sensitive Learning)

핵심 질문: 모델의 예측 오류 유형에 따라 손실의 크기가 다를 때, 어떻게 총 손실을 최소화하는 최적의 결정을 내릴 수 있을까?

A.1. 사례: 의료 진단의 비대칭적 비용 (Case: Asymmetric Costs in Medical Diagnosis)

암 진단 모델을 개발하는 상황을 가정해 보겠습니다. 모델은 환자의 의료 데이터를 기반으로 종양이 '악성 (Positive)'인지 '정상(Negative)'인지를 예측합니다. 이러한 예측에는 두 가지 유형의 심각한 오류가 발생할 수 있습니다.

- **False Positive (FP):** 실제로는 정상이지만 악성으로 오진하는 경우입니다. 이로 인해 환자는 불필요한 추가 검사(예: 조직 검사)를 받게 되고, 상당한 정신적 고통과 경제적 부담을 겪을 수 있습니다.
- **False Negative (FN):** 실제로는 악성이지만 정상으로 오진하는 경우입니다. 이는 훨씬 더 치명적인 결과를 초래할 수 있습니다. 치료 시기를 놓쳐 환자의 생명을 위협할 수 있기 때문입니다.

이처럼 두 오류가 초래하는 사회적, 의학적, 경제적 비용은 명백히 비대칭적입니다. 일반적으로 FN의 비용은 FP의 비용보다 훨씬 큼니다. 이러한 비대칭적 비용 구조를 정량적으로 표현하기 위해 **비용 행렬(Cost Matrix)**을 도입할 수 있습니다. 비용은 잘못된 결정에 대한 벌점(penalty)으로 생각할 수 있으며, 올바른 결정의 비용은 0으로 설정하는 것이 일반적입니다. [의료 분야의 리스크 예측 모델 연구](#)에 따르면, 이러한 비용의 차이를 모델링에 반영하는 것이 매우 중요합니다.

	예측: 악성 (Positive)	예측: 정상 (Negative)
실제: 악성 (Positive)	$C(TP) = 0$ (비용 없음)	$C(FN)$ (매우 큰 비용)
실제: 정상 (Negative)	$C(FP)$ (상대적으로 작은 비용)	$C(TN) = 0$ (비용 없음)

이러한 상황에서 단순히 전체 예측 중 맞은 비율인 정확도(Accuracy)를 높이는 것만으로는 최적의 모델이라고 할 수 없습니다. 예를 들어, 100명 중 99명이 정상이고 1명이 악성인 데이터셋에서, 모델이 모든 환자를 '정상'으로 예측하면 정확도는 99%에 달하지만, 가장 치명적인 오류인 FN을 놓치게 됩니다. 따라서 우리는 총 기대 비용, 즉 **위험(Risk)**을 최소화하는 새로운 최적화 목표가 필요하며, 이를 **비용민감 학습(Cost-Sensitive Learning)**이라 부릅니다. [의료 데이터의 불균형 문제에 대한 연구](#)들은 비용민감 학습이 소수 클래스에 대한 성능을 개선하는 효과적인 접근법임을 강조합니다.

A.2. 이론: 결정 규칙, 임계값 최적화, 정규화 사전의 역할 (Theory: Decision Rule, Threshold Optimization, Role of Regularization Prior)

결정 규칙 (Decision Rule)의 정의

분류 모델은 보통 특정 클래스(예: 악성 종양)에 속할 사후 확률(posterior probability) $P(Y=1 | X=x)$ 를 출력합니다. 이 확률값을 바탕으로 최종적인 '결정'을 내리기 위해서는 특정 **임계값(threshold)** τ 와 비교하는 규칙이 필요합니다.

```
If  $P(Y=1|x) > \tau$ , predict Positive.
Else, predict Negative.
```

일반적으로 임계값은 0.5로 설정되지만, 이는 두 종류의 오류 비용이 같다고 암묵적으로 가정하는 것과 같습니다. 비용이 비대칭적인 경우, 이 임계값을 최적화해야 합니다.

베이즈 위험 (Bayes Risk)

베이즈 위험은 특정 결정 규칙을 따를 때 발생하는 기대 비용(expected cost)을 의미합니다. 어떤 데이터 x 가 주어졌을 때, 각 결정에 대한 **조건부 위험(Conditional Risk)**은 다음과 같이 계산됩니다.

- 'Positive'로 예측할 때의 조건부 위험:

$$R(\text{predict Positive} | x) = C(FP) \cdot P(Y=0|x) + C(TP) \cdot P(Y=1|x)$$
- 'Negative'로 예측할 때의 조건부 위험:

$$R(\text{predict Negative} | x) = C(FN) \cdot P(Y=1|x) + C(TN) \cdot P(Y=0|x)$$

베이지 결정 규칙(Bayes Decision Rule)은 모든 x 에 대해 이 조건부 위험을 최소화하는 결정을 내리는 것입니다. 즉, $R(\text{predict Positive} | x) < R(\text{predict Negative} | x)$ 일 때 'Positive'로 예측하는 것이 최적의 선택입니다.

최적 임계값(τ) 도출

위험 최소화 조건을 수식으로 풀어 최적의 임계값을 도출할 수 있습니다. 올바른 예측에 대한 비용 $C(TP)$ 와 $C(TN)$ 을 0으로 가정하면, 조건은 다음과 같이 단순화됩니다.

$$C(FP) * P(Y=0|x) < C(FN) * P(Y=1|x)$$

$P(Y=0|x) = 1 - P(Y=1|x)$ 관계를 이용하여 식을 정리하면 다음과 같습니다.

$$\begin{aligned} C(FP) * (1 - P(Y=1|x)) &< C(FN) * P(Y=1|x) \\ C(FP) &< C(FP) * P(Y=1|x) + C(FN) * P(Y=1|x) \\ C(FP) &< (C(FP) + C(FN)) * P(Y=1|x) \end{aligned}$$

따라서, 'Positive'로 예측하는 조건은 다음과 같습니다.

$$P(Y=1|x) > \frac{C(FP)}{C(FP) + C(FN)}$$

이는 최적의 임계값 τ 가 비용 구조에 의해 결정됨을 의미합니다. 이 값은 더 이상 0.5가 아니며, FN의 비용이 FP보다 훨씬 크다면 임계값은 0.5보다 훨씬 낮아져 모델이 더 쉽게 'Positive'로 예측하도록 유도합니다. 이는 소수의 오류(FP)를 감수하더라도 치명적인 오류(FN)를 피하려는 전략입니다.

정규화 사전(Regularization Prior)의 역할

베이저안 관점에서 모델 파라미터 θ 에 대한 **사전 분포(Prior Distribution)** $P(\theta)$ 는 우리의 사전 지식이나 믿음을 나타냅니다. MAP(Maximum A Posteriori) 추정에서 이 사전 분포는 정규화(Regularization) 항으로 작용하여 모델의 과적합을 방지합니다.

$$\begin{aligned} P(\theta|Data) &\propto P(Data|\theta) * P(\theta) \\ \text{Posterior} &\propto \text{Likelihood} \times \text{Prior} \end{aligned}$$

예를 들어, L2 정규화는 파라미터 θ 가 평균이 0인 가우시안 사전 분포를 따른다고 가정하는 것과 같습니다. 이는 파라미터 값들이 너무 커지지 않도록 제한하여 모델을 더 부드럽게(less complex) 만듭니다. [MLE와 MAP의 비교](#)에서 볼 수 있듯이, MAP는 사전 정보를 통해 추정치를 조절합니다.

비용민감 학습의 맥락에서, 잘 설정된 사전 분포(정규화)는 중요한 역할을 합니다. 데이터가 부족하거나 노이즈가 많은 상황에서 모델이 특정 데이터에 과도하게 반응하여 예측 확률이 0 또는 1과 같은 극단적인 값으로 치우치는 것을 방지합니다. 이로써 모델이 더 안정적이고 신뢰할 수 있는 확률을 출력하게 하여, 위험 기반의 의사결정 과정 전체의 안정성을 높여줍니다. 이는 [빈도주의와 베이저안 접근법의 비교](#)에서 논의되는 베이저안 접근의 유연성과 관련이 있습니다.

핵심 요약

- 베이지 위험은 예측 오류의 비대칭적 비용을 고려한 기대 손실입니다.
- 최적 결정 규칙은 각 예측에 대한 조건부 위험을 최소화하는 것이며, 이는 비용 구조에 따라 결정되는 최적 임계값(τ)을 통해 구현됩니다.

- 정규화는 베이지안 관점에서 사전 분포에 해당하며, 모델의 과적합을 방지하고 예측 확률의 안정성을 높여 위험 기반 의사결정의 신뢰도를 향상시킵니다.

A.3. 예제(퀴즈): 최적 임계값 선택 (Example(Quiz): Select the Optimal Threshold)

문제: 어떤 질병에 대한 진단 모델이 개발되었습니다. 이 질병의 유병률(사전 확률)은 2% ($P(Y=1)=0.02$)입니다. 오진에 따른 비용이 다음과 같은 비용 행렬로 주어졌을 때, 총 기대 비용(베이지 위험)을 최소화하는 최적의 확률 임계값 τ^* 를 계산하세요.

- 비용 행렬:
 - $C(FN)$ (실제 환자를 정상으로 오진): 100
 - $C(FP)$ (실제 정상을 환자로 오진): 5
 - $C(TP) = C(TN) = 0$

풀이 과정:

1. 베이지 결정 규칙은 $R(\text{predict Positive} | x) < R(\text{predict Negative} | x)$ 일 때 'Positive'로 예측하는 것입니다.
2. 이를 비용과 확률로 표현하면: $C(FP) \cdot P(Y=0|x) < C(FN) \cdot P(Y=1|x)$
3. 주어진 비용 값을 대입하고 $P(Y=0|x) = 1 - P(Y=1|x)$ 를 이용해 정리합니다:

$$5 \cdot (1 - P(Y=1|x)) < 100 \cdot P(Y=1|x)$$

4. 부등식을 $P(Y=1|x)$ 에 대해 풀입니다:

$$\begin{aligned} 5 - 5 \cdot P(Y=1|x) &< 100 \cdot P(Y=1|x) \\ 5 &< 105 \cdot P(Y=1|x) \\ P(Y=1|x) &> 5 / 105 \end{aligned}$$

5. 최적 임계값을 계산합니다: $\tau^* = 5 / 105 \approx 0.0476$

정답: 최적 임계값 τ^* 는 약 **0.0476**입니다. 이는 모델이 예측한 질병 확률이 4.76%만 넘어도 '환자'로 결정하는 것이 총 기대 비용을 최소화하는 가장 합리적인 전략임을 의미합니다. FN의 비용이 매우 높기 때문에, 약간의 의심만 있어도 일단 '환자'로 분류하여 더 정밀한 검사를 받도록 하는 것이 더 낫다는 결론입니다.

B. 일반화 선형모형(GLM)과 링크함수 (Generalized Linear Models (GLM) and Link Functions)

핵심 질문: 결과값이 특정 구간(예: 0 또는 1)이나 형태(예: 0 이상의 정수)를 가질 때, 어떻게 선형 모델의 예측력을 유연하게 확장할 수 있을까?

B.1. 사례: 다양한 데이터 유형에 대한 회귀 분석 (Case: Regression for Various Data Types)

전통적인 선형 회귀는 반응 변수(Y)가 연속적이고 정규분포를 따른다고 가정합니다. 하지만 현실의 데이터는 훨씬 다양합니다.

시나리오 1: 포아송 회귀 (Poisson Regression)

문제: 한 시간 동안 특정 교차로를 통과하는 차량의 수, 하루 동안 웹사이트에서 발생하는 클릭 수, 또는 특정 지역의 연간 범죄 발생 건수와 같은 '카운트 데이터(count data)'를 예측하고자 합니다. 이러한 데이터는 0 이상의 정수 값


을 가지며, 음수가 될 수 없습니다. 일반 선형 회귀 모델 $Y = \mathbf{X}\beta + \epsilon$ 을 사용하면 예측값이 음수가 나올 수 있어 현실을 제대로 반영하지 못합니다.

해결책: 이 경우, 반응 변수가 포아송 분포를 따른다고 가정하는 것이 더 합리적입니다. 포아송 회귀는 예측값의 로그(log)를 선형 모델에 연결하여 항상 양수의 예측값을 보장합니다. 즉, $\log(E[Y]) = \mathbf{X}\beta$ 입니다.

시나리오 2: 로지스틱 회귀 (Logistic Regression)

문제: 내일 비가 올지(1) 안 올지(0), 이메일이 스팸인지(1) 아닌지(0), 혹은 환자가 특정 질병을 가지고 있는지(1) 아닌지(0)와 같은 '이항(binomial) 데이터'를 예측하고자 합니다. 이 경우 결과는 '확률'로 해석되어야 하므로 0과 1 사이의 값을 가져야 합니다. 일반 선형 회귀는 이 범위를 벗어나는 예측을 할 수 있습니다.

해결책: 반응 변수가 베르누이 분포를 따른다고 가정하고, 성공 확률 p 의 로짓(logit) 변환 값을 선형 모델에 연결하는 로지스틱 회귀를 사용합니다. 즉, $\text{logit}(p) = \log\left(\frac{p}{1-p}\right) = \mathbf{X}\beta$ 입니다. 이 변환을 통해 선형 예측자의 결과($-\infty \sim +\infty$)를 확률(0 ~ 1)로 매핑할 수 있습니다.



시그모이드 함수(좌)는 선형 모델의 출력을 0과 1 사이의 부드러운 확률 값으로 변환하여 로지스틱 회귀에 사용되며, 이는 불연속적인 계단 함수(우)와 대조됩니다.

이처럼 다양한 유형의 데이터를 다루기 위해 매년 새로운 모델을 개발하는 것은 비효율적입니다. **일반화 선형 모형 (Generalized Linear Models, GLM)**은 이러한 문제들을 하나의 통합된 프레임워크로 해결하기 위해 등장했습니다. **GLM에 대한 강의 자료**는 이러한 모델들이 어떻게 선형 회귀를 확장하는지 잘 보여줍니다.

B.2. 이론: 지수족, 캐노니컬 링크, MLE (Theory: Exponential Family, Canonical Link, MLE)

GLM은 세 가지 핵심 요소로 구성됩니다.

- 확률 요소 (Random Component):** 반응 변수 Y 가 따르는 확률 분포를 지정합니다. 이 분포는 반드시 **지수족(Exponential Family)**에 속해야 합니다.
- 체계적 요소 (Systematic Component):** 설명 변수 X 들의 선형 결합으로 정의되는 **선형 예측자(linear predictor)** $\eta = \mathbf{X}\beta$ 입니다.
- 연결 함수 (Link Function):** 확률 요소의 기댓값 $\mu = E[Y]$ 와 체계적 요소 η 를 연결하는 미분 가능한 함수 $g(\cdot)$ 입니다. 즉, $g(\mu) = \eta = \mathbf{X}\beta$ 입니다.

지수족 (Exponential Family)

지수족은 많은 중요한 확률 분포(정규, 베르누이, 이항, 포아송, 감마 등)를 포괄하는 일반적인 형태의 분포 클래스입니다. 그 확률(밀도) 함수는 다음과 같은 형태로 표현될 수 있습니다.

$$f(y; \theta) = h(y) \cdot \exp(\eta(\theta) \cdot T(y) - A(\theta))$$

- θ : 분포의 자연 모수(natural parameter)
- $\eta(\theta)$: 자연 모수를 캐노니컬 파라미터로 변환하는 함수

- $T(y)$: 충분 통계량(sufficient statistic)
- $A(\theta)$: 로그 분할 함수(log-partition function)

분포가 지수족에 속하면 우도 함수가 다루기 좋은 형태가 되어, GLM의 이론적 기반을 제공하고 최대우도추정(MLE)을 통한 파라미터 추정을 용이하게 합니다.

캐노니컬 링크 (Canonical Link)

캐노니컬 링크는 각 지수족 분포에서 가장 자연스럽게 유도되는 '표준' 연결 함수입니다. 이는 선형 예측자 η 가 분포의 자연 모수 θ 와 같아지도록($\eta = \theta$) 하는 링크 함수를 의미합니다. 캐노니컬 링크를 사용하면 수학적 계산이 간편해지고 통계적으로도 좋은 성질을 가집니다.

분포 (확률 요소)	기댓값 μ	캐노니컬 링크 $g(\mu)$	모델 이름
정규분포	μ	$g(\mu) = \mu$ (항등 함수)	선형 회귀
베르누이/이항분포	p (성공 확률)	$g(p) = \log\left(\frac{p}{1-p}\right)$ (로짓 함수)	로지스틱 회귀
포아송분포	λ (평균 발생률)	$g(\lambda) = \log(\lambda)$ (로그 함수)	포아송 회귀

최대우도추정 (Maximum Likelihood Estimation, MLE)

GLM의 회귀 계수 β 는 주어진 데이터가 현재 모델 하에서 나타날 가능성, 즉 **우도(Likelihood)**를 최대로 만드는 값으로 추정됩니다. [로지스틱 회귀의 계수 추정](#)에서 설명하듯이, 이 과정은 일반적으로 로그 우도 함수(log-likelihood function) $\ell(\beta; \mathbf{y}) = \log L(\beta; \mathbf{y})$ 를 최적화하는 방식으로 이루어집니다.

로그 우도 함수를 β 에 대해 미분하여 그 값이 0이 되는 지점을 찾음으로써 최적의 β 를 구할 수 있습니다. 하지만 대부분의 GLM에서는 이 방정식이 닫힌 형태(closed-form)로 풀리지 않기 때문에, 경사 하강법(Gradient Descent)과 같은 수치적 최적화 알고리즘을 사용하여 해를 찾습니다. [MLE를 통한 로지스틱 회귀 모델 추정](#)은 이러한 최적화 과정의 중요성을 잘 보여줍니다.

B.3. 예제(퀴즈): 지수족 로그우도 형태 식별 (Example(Quiz): Identify Exponential Family Form)

문제: 포아송 분포의 확률 질량 함수(PMF)는 $P(Y=y) = \frac{\lambda^y e^{-\lambda}}{y!}$ 입니다. 이 식을 지수족의 일반 형태 $f(y; \lambda) = h(y) \exp(\eta(\lambda) T(y) - A(\lambda))$ 로 변환하고, 각 구성요소 $h(y)$, $\eta(\lambda)$, $T(y)$, $A(\lambda)$ 를 식별하세요.

풀이 과정:

- 주어진 PMF를 $\exp$ 함수를 사용하여 재정리합니다. 지수와 로그의 관계($a = \exp(\log a)$)를 이용합니다.

$$P(Y=y) = \frac{\lambda^y e^{-\lambda}}{y!} = \frac{1}{y!} \cdot \exp(\log(\lambda^y e^{-\lambda}))$$

- $\exp$ 항들을 하나로 합칩니다.

$$P(Y=y) = \frac{1}{y!} \exp(y \log \lambda - \lambda)$$

- 이 식을 지수족 일반 형태 $h(y) \exp(\eta(\lambda) T(y) - A(\lambda))$ 와 비교합니다.
 - y 에만 의존하는 항: $h(y) = \frac{1}{y!}$

- y 와 λ 가 곱해진 항의 계수: $\eta(\lambda) = \log \lambda$ (이것이 캐노니컬 파라미터입니다.)
- $\eta(\lambda)$ 에 곱해지는 y 의 함수: $T(y) = y$ (충분 통계량)
- λ 에만 의존하는 항: $A(\lambda) = \lambda$

정답: 각 구성요소는 다음과 같습니다: $h(y) = 1/y!$, $\eta(\lambda) = \log \lambda$, $T(y) = y$, $A(\lambda) = \lambda$. 여기서 캐노니컬 파라미터와 기댓값($\mu = \lambda$)의 관계를 나타내는 캐노니컬 링크 함수는 $\eta = \log \lambda$ 이므로, 포아송 분포의 캐노니컬 링크는 로그 링크임을 확인할 수 있습니다.

C. 보정(calibration)과 예측확률의 품질 (Calibration and Quality of Predicted Probabilities)

핵심 질문: 모델이 "비가 올 확률 80%"라고 예측했을 때, 우리는 이 80%라는 숫자를 얼마나 신뢰할 수 있는가?

C.1. 사례: 날씨 예측의 신뢰도 (Case: Reliability of Weather Forecasts)


기상청에서 개발한 강수 예측 모델이 "내일 비가 올 확률은 30%"라고 예보했다고 가정해 봅시다. 이 예측은 단순히 '비가 온다/안 온다'는 이진 분류를 넘어, 불확실성의 정도를 정량적으로 제시합니다. 하지만 이 30%라는 숫자는 얼마나 신뢰할 수 있을까요?

모델이 **잘 보정(well-calibrated)**되었다는 것은 예측된 확률이 실제 사건의 발생 빈도와 일치함을 의미합니다. 즉, 모델이 30%의 강수 확률을 예측했던 모든 날들을 모아봤을 때, 실제로 그 중 약 30%의 날에 비가 왔어야 합니다. 만약 실제로는 10%의 날에만 비가 왔다면 모델은 과신(over-confident)하는 경향이 있고, 50%의 날에 비가 왔다면 과소평가(under-confident)하는 경향이 있는 것입니다. **예보 보정(Forecast Calibration)**은 이러한 예측 확률을 실제 관측과 일치시키는 과정을 의미합니다.

이러한 보정 상태를 시각적으로 평가하는 도구가 바로 **신뢰도 다이어그램(Reliability Diagram)**입니다. 이 다이어그램은 모델의 예측 확률을 여러 구간(bin)으로 나눈 뒤, 각 구간별 평균 예측 확률과 실제 결과의 비율을 비교하여 그립니다.

- **X축:** 예측된 확률 구간의 평균값 (예: 0.25, 0.75)
- **Y축:** 해당 구간에 속한 예측들 중 실제 양성(positive) 결과의 비율


완벽하게 보정된 모델의 경우, 모든 점들이 $y=x$ 대각선(perfect calibration line) 위에 위치하게 됩니다.



완벽하게 보정된 모델의 신뢰도 다이어그램. 예측 확률(X축)과 실제 양성 비율(Y축)이 일치하여 $y=x$ 대각선을 따른다

아래는 실제 모델의 신뢰도 다이어그램을 시각화한 예시입니다. 모델의 예측이 대각선에서 얼마나 벗어나는지를 통해 보정 상태를 직관적으로 파악할 수 있습니다.

신뢰도 다이어그램 (Reliability Diagram)



B.2. 이론: 브라이어 점수 / ECE 개념 (Theory: Brier Score / ECE Concept)

정확도(Accuracy)나 AUC(Area Under the ROC Curve)와 같은 전통적인 분류 지표는 모델이 클래스를 얼마나 잘 '구분'하는지, 즉 순위 결정 능력은 보여주지만, 예측된 확률 값 자체의 신뢰도를 직접적으로 측정하지는 못합니다. 예를 들어, 두 모델이 동일한 AUC 점수를 갖더라도 한 모델은 잘 보정된 확률을 제공하는 반면 다른 모델은 그렇지 않을 수 있습니다. 따라서 예측 확률의 품질을 평가하기 위한 별도의 지표가 필요합니다.

브라이어 점수 (Brier Score)

브라이어 점수는 예측 확률의 정확도를 측정하는 대표적인 지표로, 본질적으로 예측 확률과 실제 결과 사이의 평균 제곱 오차(Mean Squared Error)입니다. [Brier Score에 대한 설명](#)에 따르면, 이 점수는 일종의 비용 함수로, 낮을수록 좋습니다.

이진 분류 문제에 대한 Brier Score의 공식은 다음과 같습니다.

$$BS = (1/N) * \sum (p_i - o_i)^2 \quad (i=1 \text{ to } N)$$

- N : 전체 예측의 수
- p_i : i 번째 예측의 확률 (예: 0.7)
- o_i : i 번째 실제 결과 (사건 발생 시 1, 미발생 시 0)

Brier Score는 0에서 1 사이의 값을 가지며, 0에 가까울수록 완벽한 예측을 의미합니다. 이 점수는 모델의 **보정(calibration)** 능력과 **해상도(resolution)** , 즉 다른 결과를 가진 사례들에 대해 얼마나 다른 확률을 부여하는지 두 가지 요소를 종합적으로 반영합니다.

기대 보정 오차 (Expected Calibration Error, ECE)

기대 보정 오차(ECE)는 신뢰도 다이어그램의 아이디어를 수치화한 것으로, 모델의 보정 정도만을 순수하게 측정하기 위한 지표입니다. ECE는 예측 확률과 실제 빈도 사이의 차이를 정량화합니다.

ECE의 계산 과정은 다음과 같습니다.

1. 모든 예측을 확률값에 따라 M 개의 구간(bin)으로 나눕니다. (예: 10개의 구간, $[0, 0.1]$, $(0.1, 0.2]$, ...)
2. 각 구간 B_m 에 대해, 평균 예측 확률(confidence)과 실제 양성 비율(accuracy)을 계산합니다.
 - 구간의 평균 신뢰도: $\text{conf}(B_m) = \frac{1}{|B_m|} \sum_{i \in B_m} p_i$
 - 구간의 실제 정확도: $\text{acc}(B_m) = \frac{1}{|B_m|} \sum_{i \in B_m} o_i$
3. 전체 구간에 대해 신뢰도와 정확도 차이의 가중 평균을 계산합니다.

$$ECE = \sum (|B_m|/N) * |acc(B_m) - conf(B_m)| \quad (m=1 \text{ to } M)$$

ECE 값이 0에 가까울수록 모델이 더 잘 보정되었음을 의미합니다. 이는 신뢰도 다이어그램에서 점들이 대각선에 얼마나 가까운지를 나타내는 수치적 척도입니다.

C.3. 예제(퀴즈): 주어진 버킷의 Brier 계산 (Example(Quiz): Calculate Brier Score for a Given Bucket)

문제: 날씨 예측 모델이 10일 동안 특정 지역의 강수 확률을 예측했습니다. 이 10개의 예측은 모두 0.7에서 0.8 사이의 확률 구간(bucket)에 속했으며, 이 구간의 평균 예측 확률(confidence)은 0.75였습니다. 10일 중 실제로 비가 온 날은 8일이었습니다. 이 10개 예측에 대한 Brier Score를 계산하세요.

풀이 과정:

1. Brier Score 공식은 $BS = \frac{1}{N} \sum_{i=1}^N (p_i - o_i)^2$ 입니다. 문제의 편의를 위해 모든 예측 확률 p_i 가 구간의 평균인 0.75라고 가정하겠습니다.
2. 실제로 비가 온 8일($o_i=1$)에 대한 오차 제곱의 합을 계산합니다:

$$8 * (0.75 - 1)^2 = 8 * (-0.25)^2 = 8 * 0.0625 = 0.5$$

3. 실제로 비가 오지 않은 2일($o_i=0$)에 대한 오차 제곱의 합을 계산합니다:

$$2 * (0.75 - 0)^2 = 2 * (0.75)^2 = 2 * 0.5625 = 1.125$$

4. 모든 오차 제곱의 합을 구합니다:

$$\text{Total Squared Error} = 0.5 + 1.125 = 1.625$$

5. 전체 예측 수($N=10$)로 나누어 평균, 즉 Brier Score를 계산합니다:

$$\text{Brier Score} = 1.625 / 10 = 0.1625$$

정답: 이 10개 예측에 대한 Brier Score는 **0.1625**입니다.

챕터 요약 및 다음 단계 (Chapter Summary & Next Steps)

이번 챕터에서는 확률적 예측을 실제 의사결정에 연결하는 세 가지 중요한 개념을 학습했습니다.

- **베이즈 위험**을 통해 오류의 기대치적 비용을 고려하여 최적의 결정 임계값을 찾는 방법을 배웠습니다. 이를 통해 우리는 현실 세계의 문제에서 총 기대 손실을 최소화하는 합리적인 결정을 내릴 수 있습니다.
- **일반화 선형 모형(GLM)**을 통해 반응 변수가 정규분포를 따르지 않는 다양한 데이터 유형(카운트, 이진 데이터 등)을 일관된 프레임워크 안에서 모델링하는 유연성을 확보했습니다.
- **보정(Calibration)**과 관련 지표(Brier Score, ECE)를 통해 모델이 출력하는 확률 값의 신뢰도를 정량적으로 평가하는 방법을 익혔습니다. 이는 모델의 예측을 맹신하는 것이 아니라, 그 예측의 품질을 비판적으로 검토하는 데 필수적입니다.

이로써 우리는 단순히 '정확하게 맞추는' 모델을 넘어, 불확실성과 비용을 고려하여 '현명한 결정'을 내리는 모델을 설계하고 평가할 수 있는 견고한 이론적 토대를 마련했습니다. 다음 챕터에서는 이러한 개념들을 바탕으로, 더 복잡한 비선형 관계를 모델링할 수 있는 고급 모델 구조와 학습 알고리즘에 대해 탐구할 것입니다.

참고 자료

[1] Generalized Linear Models in R

<https://www.datacamp.com/doc/r/glm>

[2] Brier Score: Understanding Model Calibration

<https://neptune.ai/blog/brier-score-and-model-calibration>

[3] Generalized Linear Models (GLMs)

<https://www.sjsu.edu/faculty/guangliang.chen/Math261a/Ch13slides-generalized-linear-models.pdf>